



SAPIENZA
UNIVERSITÀ DI ROMA

Colorazione di grafi mediante Graph Neural Network e minimizzazione differenziabile dell'energia di Potts

Eleonora De Cicco 2047514

Mariagiusti Nicodemo 2114171

Relazione di progetto — Docente: Prof. Stefano Giagu — A.A. 2025–2026

Sommario

Si studia il problema della colorazione di due grafi DIMACS mediante una Graph Neural Network (GNN) addestrata separatamente su ogni istanza e su ogni numero di colori c . La rete produce assegnazioni continue, ottimizzate minimizzando una loss ispirata all'hamiltoniana antiferromagnetica di Potts; l'output viene discretizzato con $\arg \max$ e raffinato tramite ricerca locale *min-conflicts*. La scansione robusta su cinque seed trova colorazioni valide GNN+repair con $c = 11$ per g6 e $c = 35$ per g12, con tasso di successo pari al 40% in entrambi i casi. Una baseline greedy ottiene rispettivamente 13 e 31 colori: la pipeline neurale migliora quindi l'upper bound su g6, ma non su g12. L'analisi evidenzia la sensibilità all'inizializzazione, la differenza fra loss continua e validità discreta e il ruolo determinante del post-processing.

1. Introduzione e descrizione del problema

Dato un grafo non orientato $G = (V, E)$, una colorazione con c colori è una funzione $q : V \rightarrow \{1, \dots, c\}$. Essa è valida se $q_i \neq q_j$ per ogni arco $(i, j) \in E$. Equivalentemente, il numero di conflitti

$$N_{\text{conf}}(q) = \sum_{(i,j) \in E} \mathbf{1}[q_i = q_j] \quad (1)$$

deve essere nullo. Il minimo c ammissibile è il numero cromatico $\chi(G)$, la cui determinazione è NP-hard. Il problema viene riformulato come ottimizzazione differenziabile: una GNN produce una rappresentazione continua dei colori e viene addestrata direttamente sul singolo grafo.

Sono analizzate le istanze g6 e g12, le cui proprietà sono riportate in Tabella 1.

Tabella 1: Caratteristiche delle istanze dopo il parsing e la deduplicazione.

Grafo	$ V $	$ E $	Densità	$d_{\min}$	$\bar{d}$	$d_{\max}$
g6	81	1056	0.326	24	26.07	32
g12	186	3973	0.231	0	42.72	159

1.1. Struttura delle istanze

La sola dimensione non descrive completamente la difficoltà delle istanze. Come mostra la Figura 1, g6 è relativamente regolare: tutti i nodi hanno grado compreso fra 24 e 32. g12 è invece fortemente eterogeneo: contiene 10 nodi isolati, molti nodi con grado vicino a 30 e pochi hub con grado superiore a 100, fino al massimo di 159. I nodi isolati non contribuiscono alla loss né ai conflitti e possono ricevere un colore arbitrario; gli hub impongono invece vincoli simultanei su una porzione ampia del grafo. Questa eterogeneità può contribuire al paesaggio di ottimizzazione più irregolare osservato su g12.

Distribuzione dei gradi delle istanze




Figura 1: Distribuzione dei gradi. g6 presenta una struttura quasi regolare, mentre g12 combina nodi isolati e hub ad alto grado.

2. Strategia utilizzata e architettura

2.1. Rappresentazione e message passing

I grafi sono letti dal formato DIMACS e convertiti in oggetti PyTorch Geometric. Per il message passing si usa una lista di archi bidirezionale; per ogni nodo i , un layer combina la rappresentazione corrente con la media di quelle dei vicini:

$$\mathbf{h}_i^{(\ell+1)} = \text{ReLU}\left(W_s \mathbf{h}_i^{(\ell)} + W_n \frac{1}{|N(i)|} \sum_{j \in N(i)} \mathbf{h}_j^{(\ell)}\right) + \mathbf{h}_i^{(\ell)}. \quad (2)$$

L'architettura comprende un embedding trainabile di dimensione 64 per nodo, due layer di message passing con connessioni residuali e un layer lineare finale con c output. La softmax trasforma i logits in $\mathbf{p}_i = (p_{i1}, \dots, p_{ic})$, interpretabile come assegnazione “soft” del nodo ai colori.

2.2. Loss di Potts, discretizzazione e repair

La funzione obiettivo normalizzata penalizza la sovrapposizione fra le distribuzioni di nodi adiacenti:

$$\mathcal{L}_{\text{Potts}} = \frac{1}{|E|} \sum_{(i,j) \in E} \mathbf{p}_i^\top \mathbf{p}_j, \quad \mathcal{L}_{\text{tot}} = \mathcal{L}_{\text{Potts}} + \lambda H, \quad (3)$$

dove $H = -|V|^{-1} \sum_i \sum_k p_{ik} \log p_{ik}$ e $\lambda = 0.02$. Poiché il termine entropico è minimizzato, favorisce distribuzioni concentrate. Durante l'addestramento si monitorano separatamente la loss continua e i conflitti della colorazione discreta $q_i = \arg \max_k p_{ik}$, poiché una loss bassa non garantisce $N_{\text{conf}} = 0$.

La migliore colorazione discreta osservata viene infine passata a una ricerca locale *min-conflicts*: a ogni passo si seleziona un nodo conflittuale e gli si assegna un colore che minimizza i conflitti con i vicini. La Figura 2 sintetizza la pipeline completa.




Figura 2: Pipeline sperimentale. La rete non è pre-addestrata: viene ottimizzata da zero per ciascuna coppia grafo- c .

3. Dettagli del training e protocollo sperimentale

L'ottimizzazione usa Adam con learning rate 10^{-2} , weight decay 10^{-5} , 700 epoche e al massimo 3000 passi di repair. La migliore soluzione raw viene aggiornata monitorando i conflitti discreti ogni 25 epoche. Per stimare la soglia di colorabilità della pipeline sono eseguite scansioni $c = 8, \dots, 12$ per g6 e $c = 20, \dots, 36$ per g12. Dopo una prima scansione con due seed, l'esperimento viene ripetuto con cinque seed $(0, \dots, 4)$, per un totale di 110 run.

Per ogni c si riportano minimo, media e deviazione standard dei conflitti dopo repair, oltre al *success rate*, cioè la frazione di run con $N_{\text{conf}} = 0$. Come controllo viene usata la baseline `greedy_color` di NetworkX con le strategie `largest_first`, `smallest_last` e `saturation_largest_first`. Ogni soluzione finale dichiarata valida viene salvata e verificata nuovamente sugli archi unici.

Per confrontare istanze con numeri di archi differenti si considera inoltre il tasso di conflitto

$$\epsilon(c) = \frac{N_{\text{conf}}(c)}{|E|}. \quad (4)$$

La statistica decisiva resta il numero assoluto di conflitti, poiché la validità richiede $N_{\text{conf}} = 0$; ϵ è però utile per interpretare soluzioni non valide su grafi di dimensione differente. Indicando con $R = 5$ il numero di restart, si calcolano anche

$$\overline{N}_{\text{conf}}(c) = \frac{1}{R} \sum_{r=1}^R N_{\text{conf}}^{(r)}(c), \quad s(c) = \frac{1}{R} \sum_{r=1}^R \mathbf{1}[N_{\text{conf}}^{(r)}(c) = 0],$$

dove $s(c)$ è il success rate.



4. Risultati

4.1. Scansione del numero di colori

La Figura 3 mostra la scansione robusta. Per g6, il miglior risultato con $c = 10$ conserva un conflitto; con $c = 11$ si ottengono due successi su cinque. Per g12, $c = 34$ lascia almeno un conflitto, mentre $c = 35$ produce due colorazioni valide. Aggiungendo un colore, entrambe le istanze vengono risolte in tutte le run.

4.2. Confronto con la baseline e verifica finale



La Tabella 3 distingue il risultato raw della rete, il risultato dopo repair e la baseline. La GNN da sola non raggiunge mai zero conflitti nelle migliori soluzioni alla soglia: il repair riduce $17 \rightarrow 0$ conflitti su g6 e $28 \rightarrow 0$ su g12. La pipeline migliora il greedy su g6, ma su g12 il greedy produce una colorazione valida con quattro colori in meno.

(a) g6: soglia osservata a $c = 11$.(b) g12: soglia osservata a $c = 35$.**Figura 3:** Conflitti dopo repair al variare di c , nella scansione a cinque seed. Sono mostrati il miglior risultato e la media sui 5 seed.**Tabella 2:** Prestazioni vicino alla soglia nella scansione robusta.

Grafo	c	$\min N_{\text{conf}}$	media N_{conf}	dev. std.	success rate
g6	10	1	3.2	1.94	0.00
	11	0	0.6	0.49	0.40
	12	0	0.0	0.00	1.00
g12	34	1	2.6	1.62	0.00
	35	0	1.0	0.89	0.40
	36	0	0.0	0.00	1.00

Tabella 3: Migliori colorazioni valide osservate. I valori di c sono upper bound sperimentali, non prove di ottimalità.

Grafo	migliore greedy	GNN+repair	seed	conflitti raw	verificati
g6		13	11	0	17
g12		31	35	2	28

g6, $c=11$, conflitti=0 (5 seed)(a) g6, $c = 11$, seed 0.g12, $c=35$, conflitti=0 (5 seed) - 10 nodi isolati mostrati in basso(b) g12, $c = 35$, seed 2.**Figura 4:** Migliori colorazioni GNN+repair verificate. Non sono presenti archi in conflitto.

4.3. Contributo quantitativo del post-processing

La Figura 5 confronta, per ogni valore di c , i conflitti medi della migliore colorazione raw osservata durante il training con quelli ottenuti dopo il repair. Nessuna delle 110 run della scansione robusta raggiunge direttamente zero conflitti con la sola GNN. Il post-processing produce invece sette run valide su g6 e sette su g12. Considerando l'intera scansione, riduce i conflitti medi da 34.64 a 8.40 su g6 e da 36.78 a 11.42 su g12, corrispondenti a riduzioni percentuali medie rispettivamente dell'81.6% e del 71.4%.




Figura 5: Conflitti medi sui cinque seed prima e dopo il repair. L'area evidenziata rappresenta il miglioramento introdotto dalla ricerca locale.

Il beneficio del repair diventa decisivo vicino alla soglia: su g6 con $c = 12$, i conflitti raw medi sono ancora 21.8, ma tutte le soluzioni vengono riparate a zero. Analogamente, su g12 con $c = 36$, la GNN lascia in media 25.4 conflitti mentre il repair risolve tutte le run. La rete sembra quindi costruire assegnazioni sufficientemente strutturate da essere completate efficacemente da una ricerca discreta, senza però risolvere autonomamente il problema.

5. Discussione critica e possibili miglioramenti

Convergenza e inizializzazione. Il metodo non converge sempre a una colorazione valida. La loss è non convessa e, vicino alla soglia, il risultato dipende sensibilmente dall'inizializzazione: il success rate è 0.40 per entrambe le migliori soluzioni GNN+repair. La scansione aggiuntiva ha infatti migliorato l'upper bound GNN+repair di g12 da 36 a 35 colori. Il successo stabile con $c = 12$ e $c = 36$ mostra che la difficoltà cresce rapidamente avvicinandosi alla soglia.

Loss continua e conflitti discreti. La loss agisce sulle distribuzioni p_i , mentre la validità dipende dagli arg max. Di conseguenza, la loss può diminuire anche quando N_{conf} rimane costante: per questo il monitoraggio discreto richiesto dalle specifiche è indispensabile. Il divario fra output raw e soluzione finale dimostra inoltre che il risultato appartiene alla pipeline ibrida, non alla sola GNN.




Figura 6: Esempio di monitoraggio congiunto su g6, $c = 9$. Loss e conflitti diminuiscono inizialmente, ma poi si stabilizzano lasciando una colorazione non valida: ottimizzare più a lungo non garantisce quindi $N_{\text{conf}} = 0$.

Interpretazione della stima. Il più piccolo c trovato dalla pipeline è 11 per g6 e 35 per g12. Questi valori costituiscono upper bound, non dimostrazioni di $\chi(G)$. Considerando anche la baseline, il miglior upper bound osservato per g12 è 31. Il fatto che una semplice euristica superi il metodo neurale su questa istanza segnala che maggiore complessità non implica automaticamente migliori soluzioni.

Limiti e sviluppi. La rete viene riaddestrata per ogni grafo, c e seed, con un costo molto superiore al greedy; inoltre, cinque seed sono sufficienti per mostrare variabilità, ma non per stimare con precisione la probabilità di successo. Miglioramenti concreti includono: più restart e early stopping sui conflitti; scheduling di learning rate, entropia o temperatura softmax; repair più forti, quali tabu search o simulated annealing; inizializzazione greedy; studi di ablazione confrontando il repair da inizializzazioni GNN, greedy e casuali; lower bound o solutori esatti per quantificare la distanza dall'ottimo.

5.1. Complessità computazionale e validità sperimentale

Per ogni configurazione, un forward pass dei due layer di message passing ha costo approssimativo $O(|E|d + |V|d^2)$, dove $d = 64$ è la dimensione nascosta. Il training moltiplica tale costo per 700 epoche, per il numero di valori di c e per i restart. Il repair può inoltre eseguire fino a 3000 passi. La pipeline è pertanto molto più costosa della baseline greedy, che produce una soluzione valida in una singola esecuzione. Il confronto dei tempi non è stato misurato su hardware controllato e costituisce un limite dell'esperimento.

I cinque seed permettono di osservare la sensibilità all'inizializzazione, ma forniscono una stima ancora grossolana del success rate: il valore 0.40 corrisponde soltanto a due successi su cinque. Inoltre, il fallimento per un dato c può dipendere dal metodo di ottimizzazione, dal budget di epoche o dal repair e non dimostra la non colorabilità matematica del grafo.

5.2. Modifiche proposte

Per separare il contributo dei componenti della pipeline sarebbe utile eseguire un insieme di studi di ablazione mantenendo fisso il budget computazionale:

- confrontare il repair inizializzato dalla GNN con inizializzazioni casuali e greedy;
- rimuovere il termine entropico oppure variare λ , misurando entropia, conflitti raw e conflitti finali;
- confrontare zero, uno e due layer di message passing, oltre alla variante senza connessioni residuali;
- misurare tempi, memoria e passi di repair, valutando qualità e costo congiuntamente.

Queste prove permetterebbero di stabilire se il message passing apprende davvero un'inizializzazione migliore o se gran parte delle prestazioni deriva dalla ricerca locale.

5.3. Interpretazione in termini di energia di Potts

Nel modello di Potts antiferromagnetico discreto, a ogni nodo è associato uno stato $q_i \in \{1, \dots, c\}$ e l'energia può essere scritta come

$$E_{\text{Potts}}(q) = \sum_{(i,j) \in E} \delta(q_i, q_j).$$

Questa espressione coincide esattamente con il numero di conflitti della Eq. (1): lo stato fondamentale a energia zero è una colorazione valida. La loss dell'Eq. (3) sostituisce gli stati discreti con distribuzioni continue e la delta di Kronecker con la sovrapposizione $\mathbf{p}_i^T \mathbf{p}_j$. La rilassazione rende possibile la discesa del gradiente, ma introduce anche stati morbidi senza equivalente discreto immediato. Il termine entropico cerca di ridurre tale discrepanza, mentre il repair riporta esplicitamente la soluzione nello spazio combinatorio.

Questa interpretazione chiarisce perché una bassa energia continua non sia sufficiente: distribuzioni parzialmente sovrapposte possono avere una loss favorevole pur producendo, dopo $\arg \max$, diversi archi conflittuali. La pipeline combina quindi tre prospettive: rilassazione fisica del problema, ottimizzazione neurale e ricerca locale discreta.

6. Conclusioni

La pipeline implementata comprende: parsing DIMACS, GNN a message passing, loss di Potts differenziabile, discretizzazione, conteggio dei conflitti, scansione in c , restart, baseline e visualizzazione. La scansione robusta trova colorazioni valide GNN+repair con 11 colori per g6 e 35 per g12; il miglior upper bound complessivo è invece 11 e 31, grazie al greedy su g12. L'esperimento conferma il valore della formulazione differenziabile come generatore di buone inizializzazioni, ma mostra anche che robustezza, post-processing e confronto con euristiche semplici sono essenziali per una valutazione corretta.

Il notebook Colab contenente l'implementazione completa, gli esperimenti e le visualizzazioni è disponibile al seguente link: <https://colab.research.google.com/drive/1VjJHC8o4940Sf6CJBONgPTW135KaMmF2#scrollTo=53ed4bcd>. Inoltre è possibile consultare la pagina GitHub per ulteriori approfondimenti al seguente link: <https://github.com/Mariagiusi23/Graph-Coloring>.

Riferimenti bibliografici

- [1] T. R. Jensen and B. Toft, *Graph Coloring Problems*, Wiley-Interscience, 1995.
- [2] T. N. Kipf and M. Welling, "Semi-Supervised Classification with Graph Convolutional Networks," *International Conference on Learning Representations*, 2017.
- [3] W. L. Hamilton, *Graph Representation Learning*, Morgan & Claypool, 2020.
- [4] M. J. A. Schuetz, J. K. Brubaker and H. G. Katzgraber, "Graph coloring with physics-inspired graph neural networks," *Physical Review Research*, 4, 043131, 2022.
- [5] S. Minton, M. D. Johnston, A. B. Philips and P. Laird, "Minimizing conflicts: a heuristic repair method for constraint satisfaction and scheduling problems," *Artificial Intelligence*, 58(1-3), 161-205, 1992.